12/24/2025

Hull Tactical Market Prediction

Team

M132040009 薄育文

M132040013 葉宇倫

M132040015 楊書暐

content

1 Introduction

2 Data

3 EDA

4 Model

5 Result

Introduction

研究背景

動機

本次研究的資料來自kaggle競賽，主辦方不滿意傳統效率市場假說。因為現實市場充斥許多違反假說的雜訊，在好奇心與商業利益的驅使下，主辦方想透過機器學習的方法找出真正有用的資訊。

問題

他們現有模型只是幾個量化策略混搭，每天收盤調曝險，方向對但太模糊，且效果不佳，他們要更好的策略，以及分析方法

要求

1. 預測報酬率：透過現有的機器學習方法，建構預測模型。
2. 設計投資策略：預測強就加碼、不確定就減倉，顧及成本與市場環境變化。

Data

資料介紹

訓練集維度：9048筆資料, 98個變數

由於資料時間跨度較大，早期資料多有缺失，因此處理缺失值會是我們初步的工作

變數欄位	說明
date_id	單一交易日的id。
M*	市場動態／技術特徵。
E*	宏觀經濟特徵。
I*	利率特徵。
P*	價格／估值特徵。
V*	波動率特徵。

變數欄位	說明
S*	情緒（市場情緒）特徵。
MOM*	動能（Momentum）特徵。
D*	虛擬／二元特徵。
forward_returns	買入標普 500，隔天賣出的報酬。
risk_free_rate	聯邦基金利率。
market_forward_excess_returns	相對於預期的前瞻報酬。以「前瞻報酬－滾動五年平均前瞻報酬」計算

EDA

檢查缺失值

方法

1. 統計整體與各特徵的缺失值比例
2. 分析缺失值是否隨時間集中出現
3. 判斷缺失是否為「系統性缺失」

缺失值矩陣

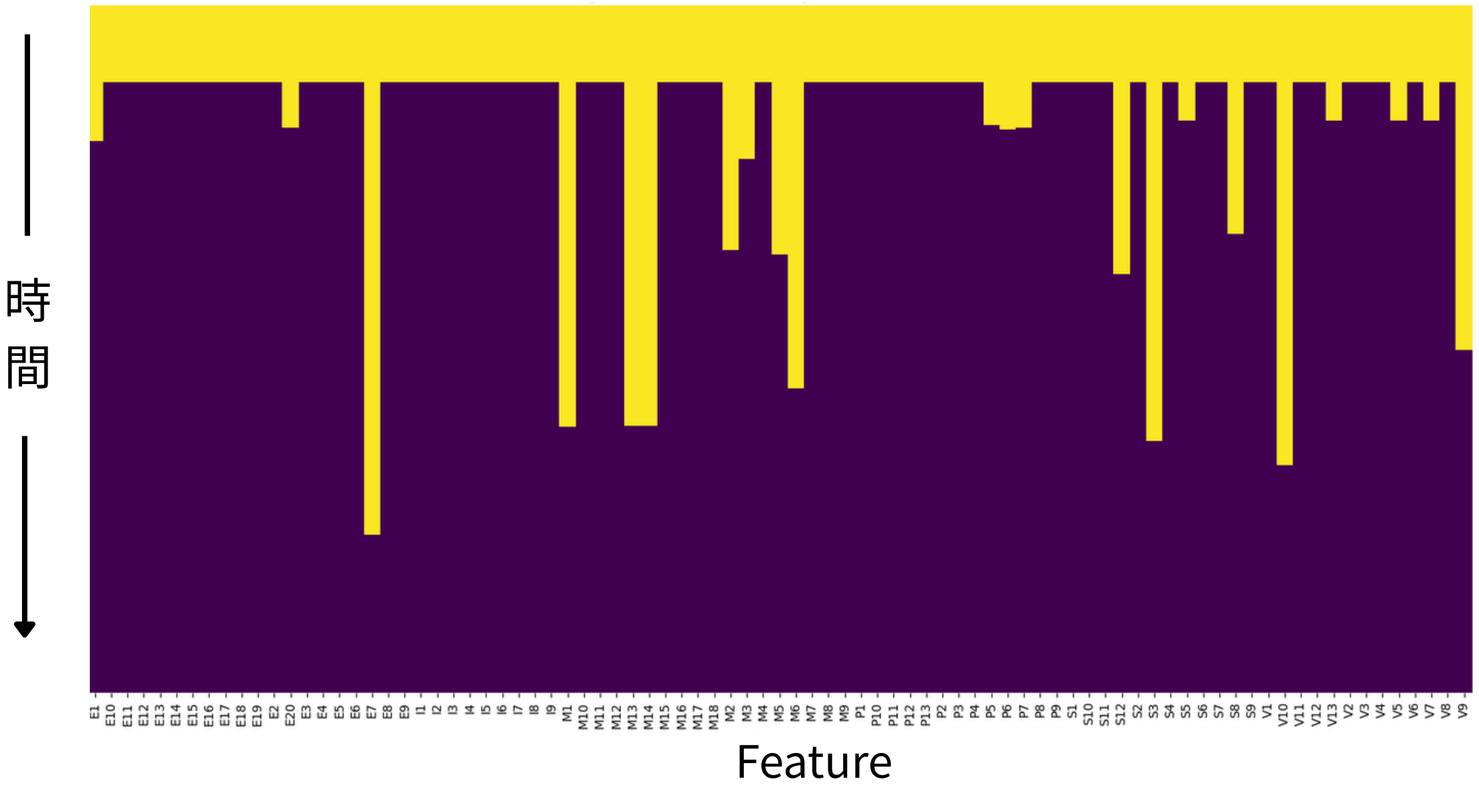

每列缺失值比率沿時間下降

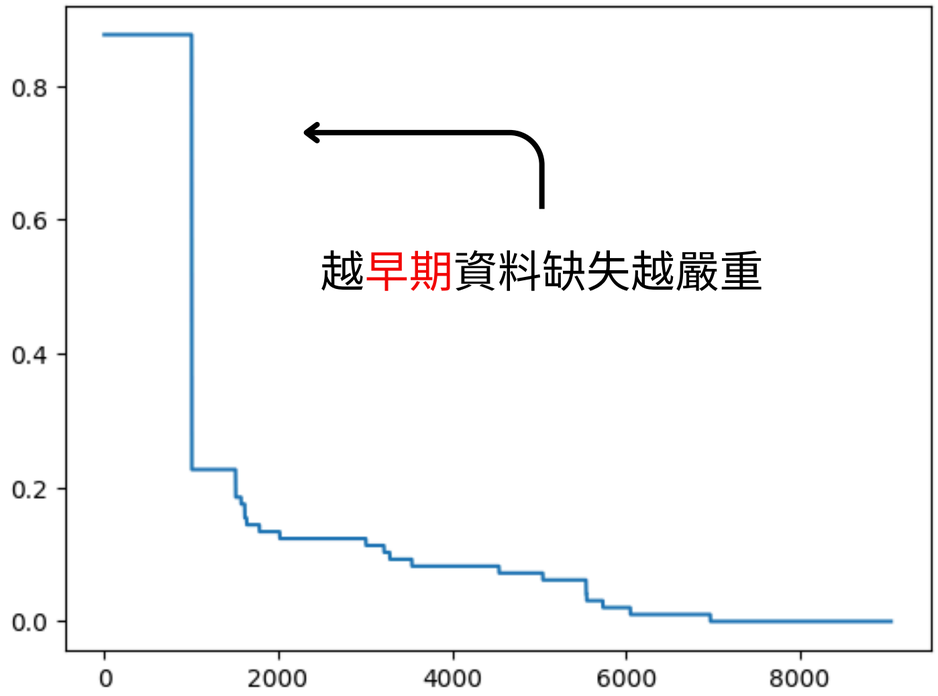

共 85 個特徵存在缺失值

缺失值處理策略

問題

傳統插補方法難以捕捉高波動時間序列之動態結構，且過久的歷史數據會削弱預測效能

方法

採用樣本刪除法：

將分析窗口限定於近8年

部分高缺失值特徵之剩餘樣本折線圖

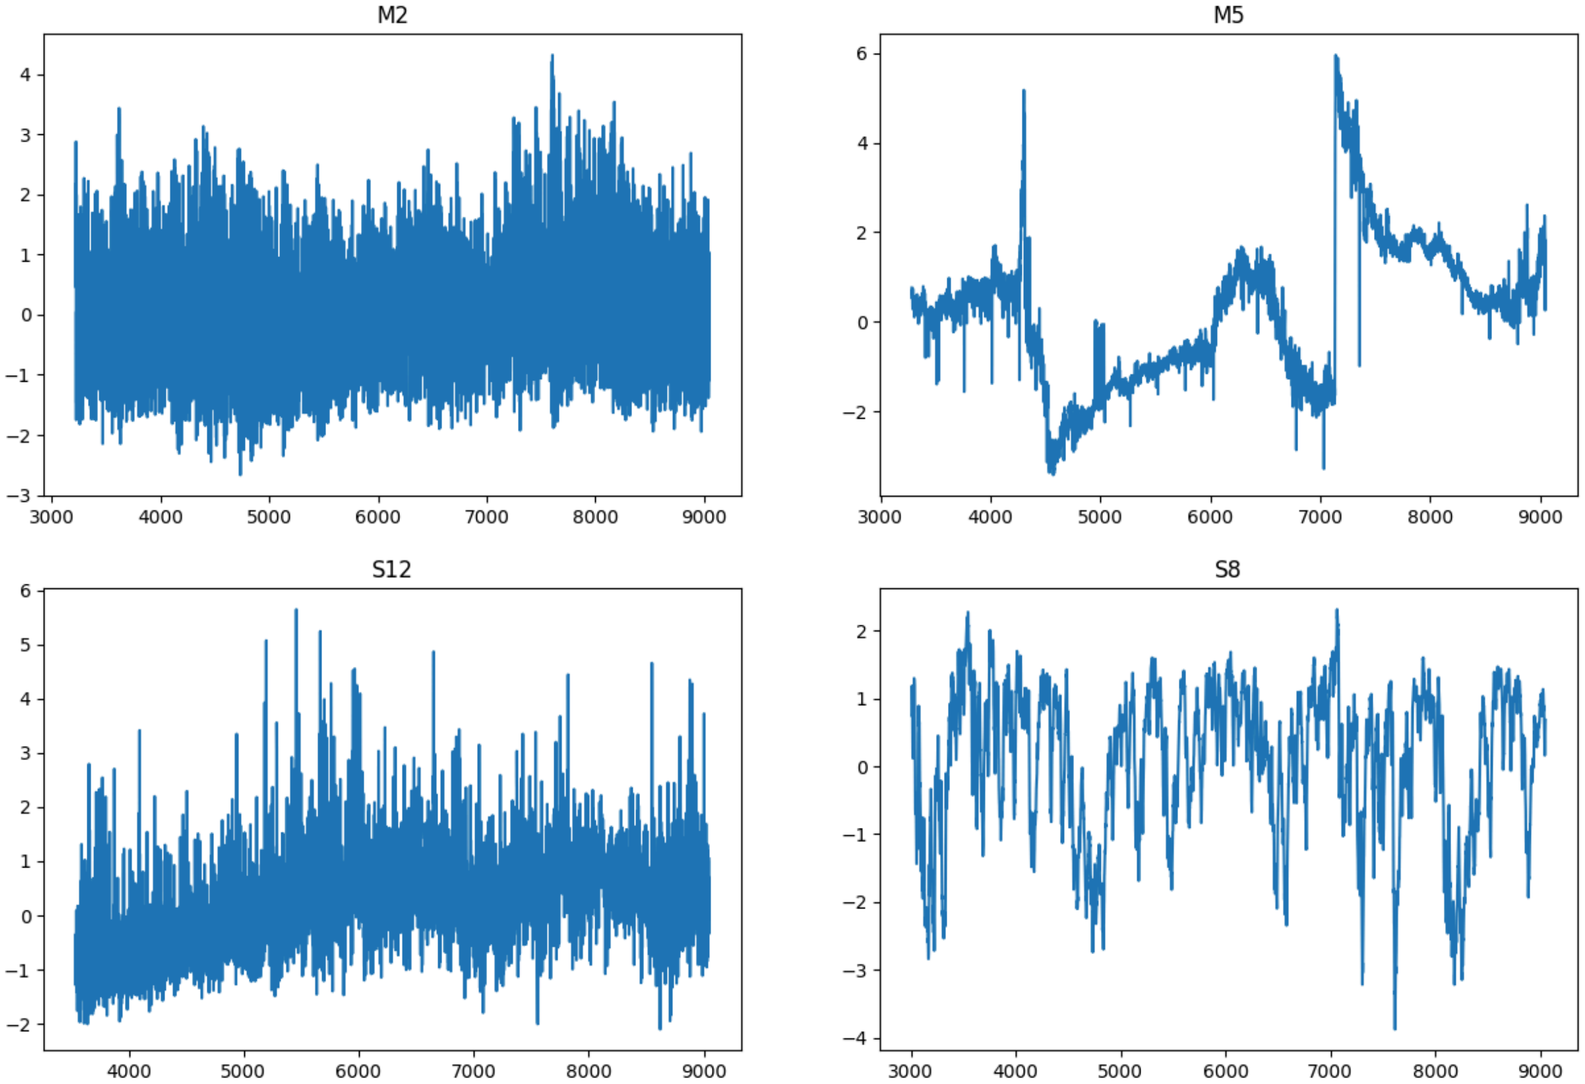

資料清洗

異常值分析與處理

用 Q1、Q3 定上下界，超過上界 → 壓回上界；低於下界 → 拉回下界（clip / winsorize）

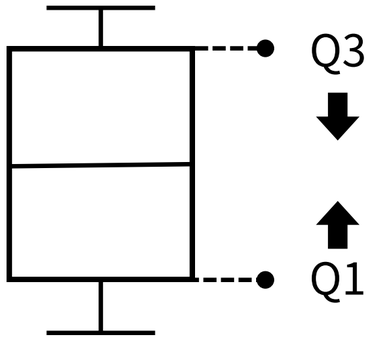

成功處理、截斷6個數值特徵

移除零變異特徵

標準差接近 0（例如 < 1e−8）→ 移除

常數特徵對模型沒有區分力

找到 D1 D2 D3 三個零變異特徵並刪掉

特徵相關性分析

計算特徵與目標變數的相關性

計算各特徵與目標變數的 Pearson correlation

↓

觀察線性關係強度

↓

初步篩選與診斷

挑出彼此有高相關性的特徵對

- 在同一類別內檢測高相關特徵對 $|r| > 0.8$
- 高冗餘特徵將於後續流程中擇一保留
- 篩選出 24 對高相關性特徵

特徵與目標變數的相關性 TOP 5	
V13	0.0596
M3	0.0554
E14	0.0544
P2	0.0486
M1	0.0472

有高相關性的特徵對

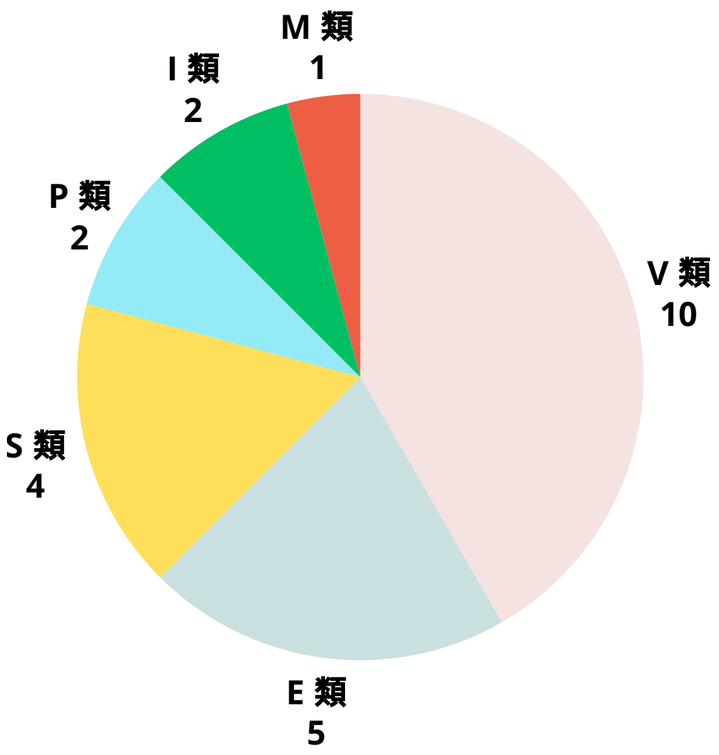

特徵重要性分析

※為避免單一指標偏誤，分析將同時考慮以下兩種關係

1. Correlation：線性關係
2. Mutual Information：非線性關係

將兩者轉為百分位排名後取平均

$$\frac{1}{2}\left[\frac{\text{rank of correlation}}{N\text{samples}} + \frac{\text{rank of MI}}{N\text{samples}}\right]$$

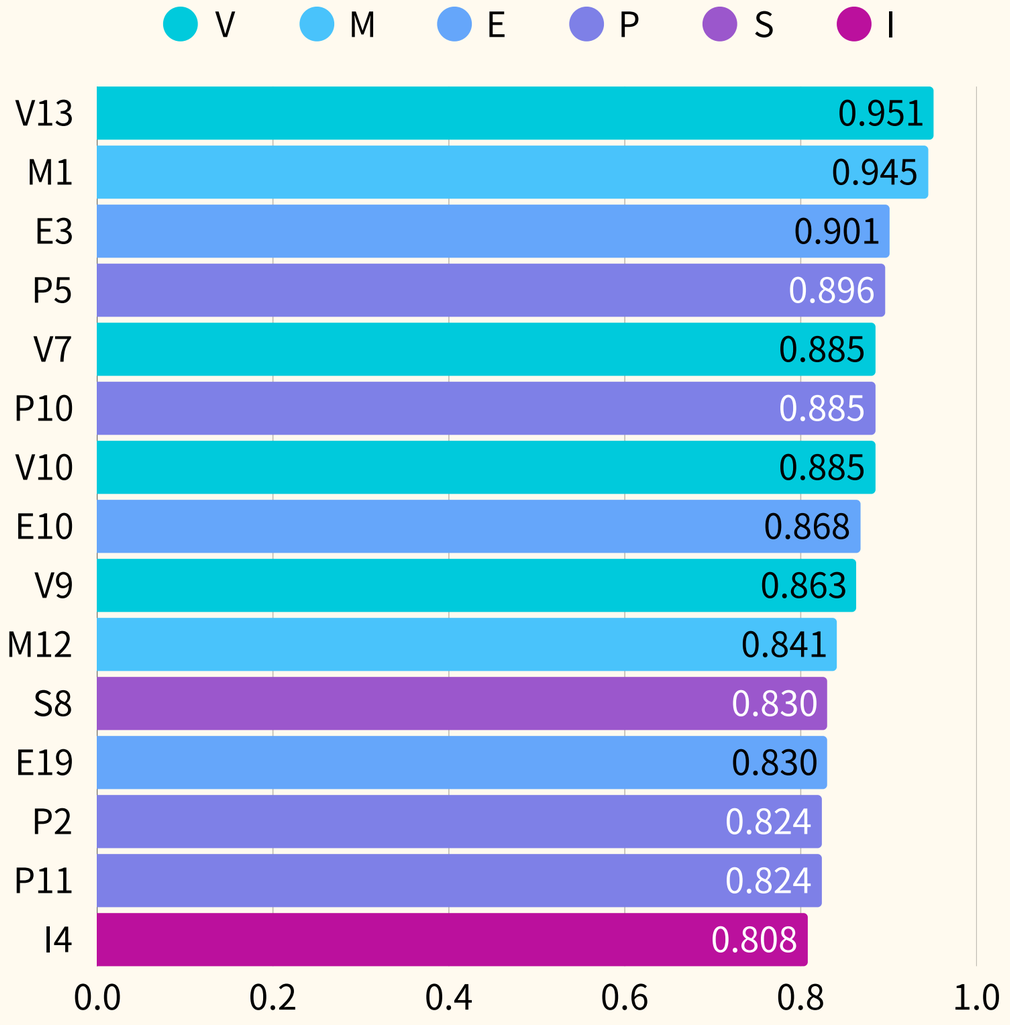

特徵穩定性分析

衡量特徵在不同時間區間中的統計穩定程度

$$\text{coefficient of variation(CV)} = \frac{\sigma}{\mu}$$

將資料依時間切分為多個 period
對每個特徵計算變異係數 (CV)：

- 平均值 CV
- 標準差 CV

若兩者皆 < 0.5

Yes → 穩定特徵

No → 非穩定特徵

篩選出 32 / 91 個變數

各類別特徵穩定數量

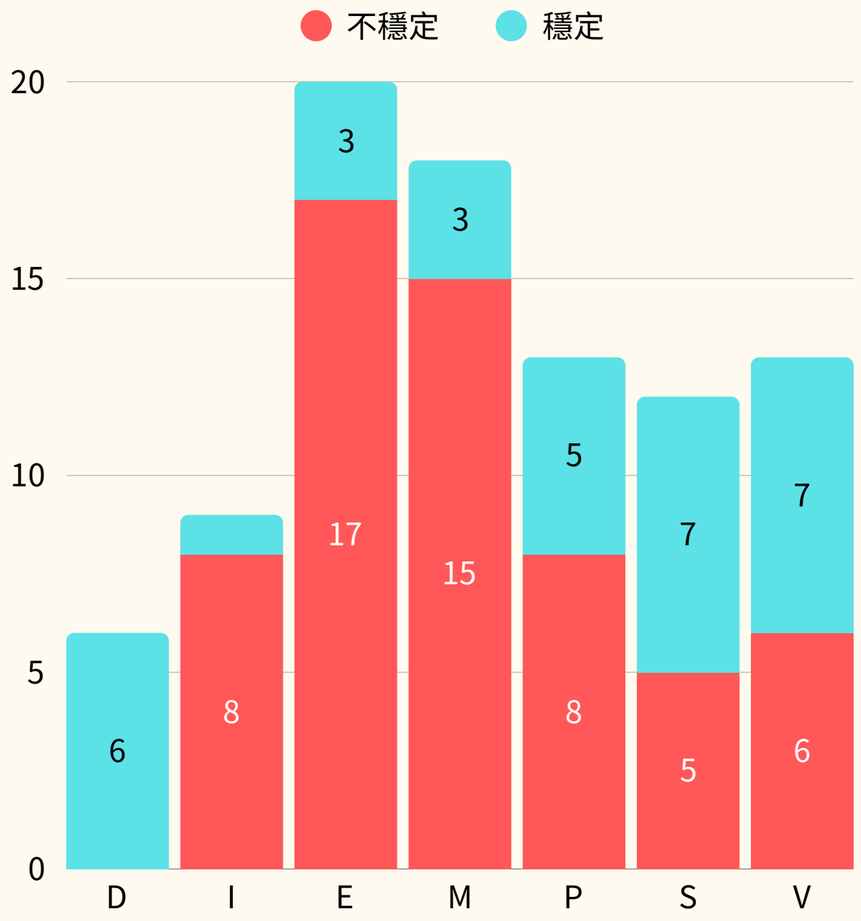

特徵篩選

01 特徵重要性分析

計算 Composite Score 保留前 70 % 特徵

※保留 65 個特徵

02 特徵穩定性分析

計算 CV 保留 < 0.5 特徵

※保留 15 個特徵

03 特徵相關性分析

計算 correlation 保留絕對值 > 0.01 特徵

※保留 13 個特徵

04 特徵間共線性分析

剔除高相關特徵對中的其中一個

※保留重要性較高者 剩餘 11 個特徵

最終特徵: D6, E14, I1, M16, M8, P1, P10, P3, S4, S6, V1

MODEL

決策方法

根據模型預測的超額報酬，決定今天要押多少比例資金

$$p_t = \text{clip}(y_t \times \text{Multipler} + 1, 0, 2) \quad y_t: \text{模型預測值}$$

市場曝險倍數 → 在看好時放大部位，風險高時退守現金

空手/避險	跟隨大盤	兩倍槓桿
100% 持有無風險資產	100% 投入市場 (S&P 500)	200% 投入市場 (積極看漲)
$p_t = 0$	$p_t = 1$	$p_t = 2$

任務 → 最大化風險調整後 Sharpe Ratio

風險調整後 Sharpe Ratio

每日報酬由「市場曝險＋無風險配置」組合而成

$$r_t^{\text{strategy}} = (1 - p_t) r_t^{\text{risk free}} + p_t r_t^{\text{market}}$$

風險懲罰: 當波動超過市場 1.2 倍時開始懲罰

$$\text{Vol Penalty} = 1 + \max\left(0, \frac{\sigma^{\text{strategy}}}{\sigma^{\text{market}}} - 1.2\right)$$

年化 Sharpe Ratio

$$\text{Sharpe} = \frac{\mathbb{E}\left[r^{\text{strategy}} - r^{\text{risk free}}\right]}{\sigma^{\text{strategy}}} \times \sqrt{252}$$

報酬落後懲罰: 若平均報酬低於市場額外扣分

$$\text{Return Penalty} = 1 + \left[\max\left(0, \left(\bar{r}^{\text{market}} - \bar{r}^{\text{strategy}} \times 252\right)\right)\right]^2$$

$$\text{Final Score} = \frac{\text{Sharpe}}{\text{Vol Penalty} \times \text{Return Penalty}}$$

有效避免模型僅透過提高槓桿或承擔過高波動來取得高分

透過 Pycaret 進行初步選擇模型

Model	Score
DecisionTree	7.60
XGBoost	7.17
ExtraTree	6.59
LightGBM	6.43
RandomForest	5.46

模型設定與預測目標

使用 market forward excess returns 作為預測目標

透過減去滾動五年平均報酬以去除長期趨勢，
並使用中位數絕對離差（MAD）進行截尾，以降低模型對尾端報酬的過度擬合風險。

模型選擇：XGBoost Regression

↑ 優點	1.可有效捕捉非線性特徵關係 2.對特徵尺度不敏感，適合經過篩選後的異質特徵集合 3.不需要過多模型假設，提供穩定的預測表現
↓ 缺點	相較於其他常見的預測模型，計算複雜度較大

誤差分析

在180筆測試資料中我們成功預測其中175筆的漲跌

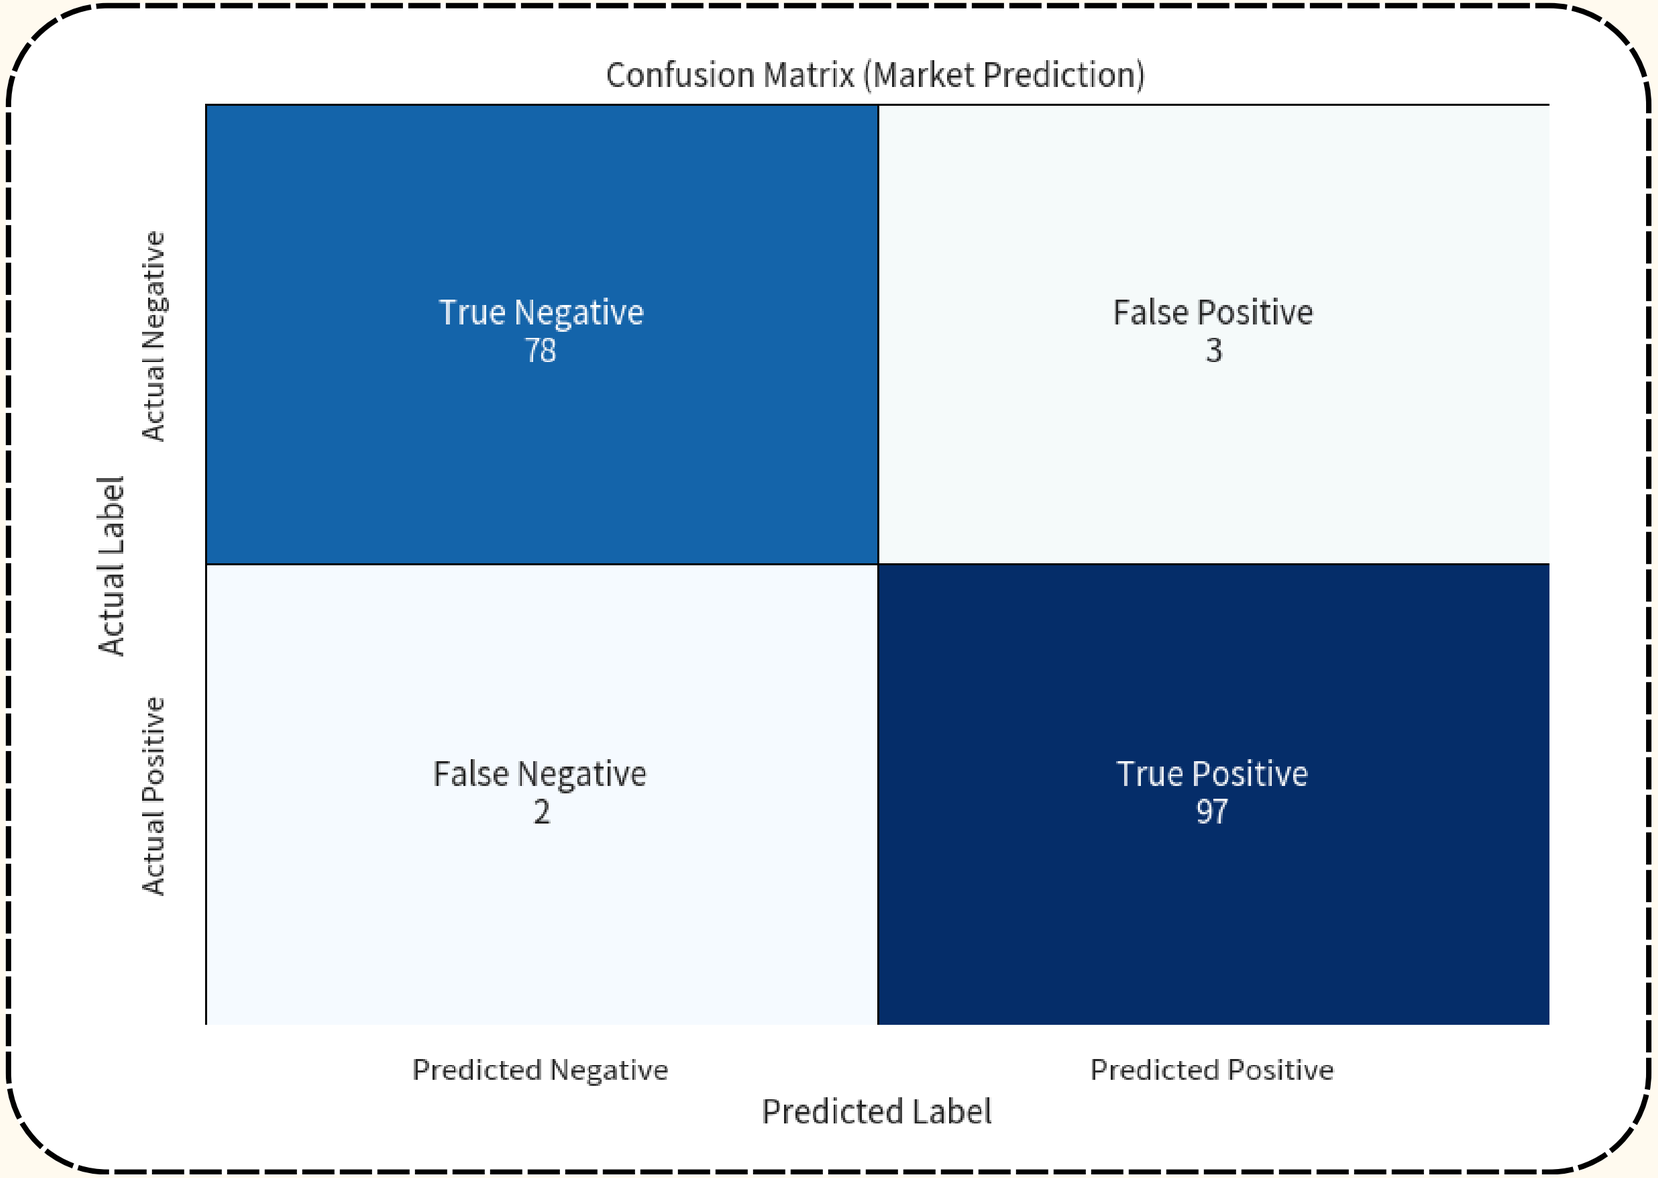

模型檢查: SHAP 局部貢獻分析

錯誤案例：模型預測看多但真實超額報酬為負

檢查方法

- 對錯誤樣本集合計算 SHAP 值
- 觀察哪些特徵把模型推向「看多」方向

使用 decision plot 顯示

各特徵對輸出的推動路徑，找出哪些特徵在錯誤案例中出現重複路徑

右圖: 模型錯誤預測樣本範例

真實值：-0.000080

預測值：0.000033

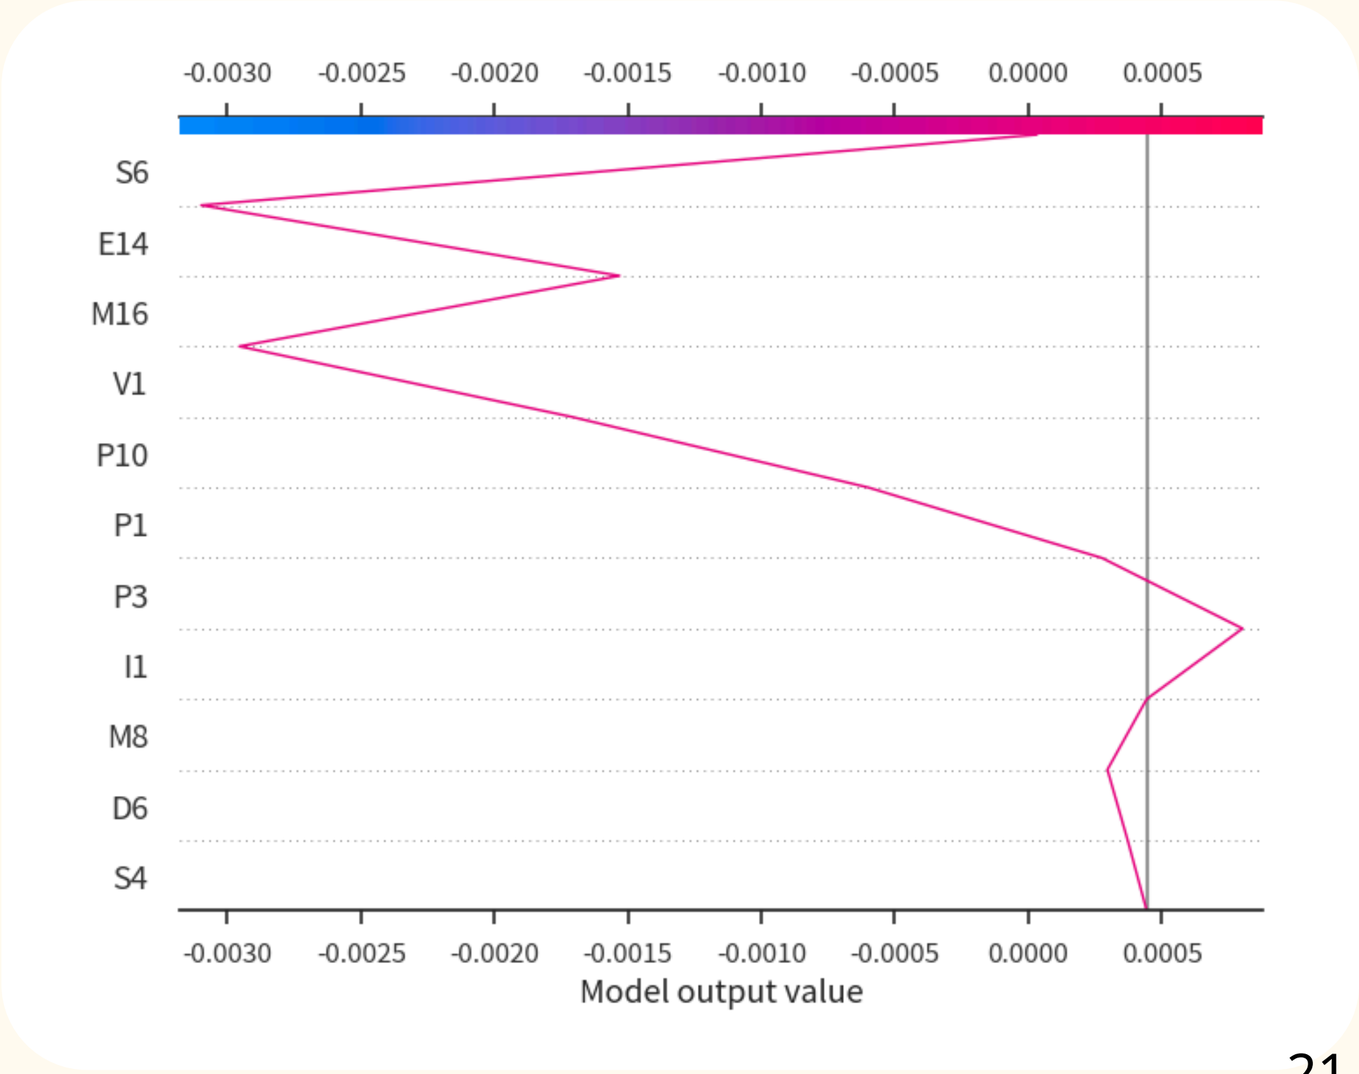

誤差分析

錯誤預測樣本數量:3

每條線代表一筆的錯誤樣本，橫軸為模型輸出，線條從 expected value 出發，經由各特徵逐步推移到最終預測。

觀察

在錯誤案例中，未觀察到特定特徵反覆主導模型輸出的情形，顯示此類錯誤未呈現明顯的結構性來源

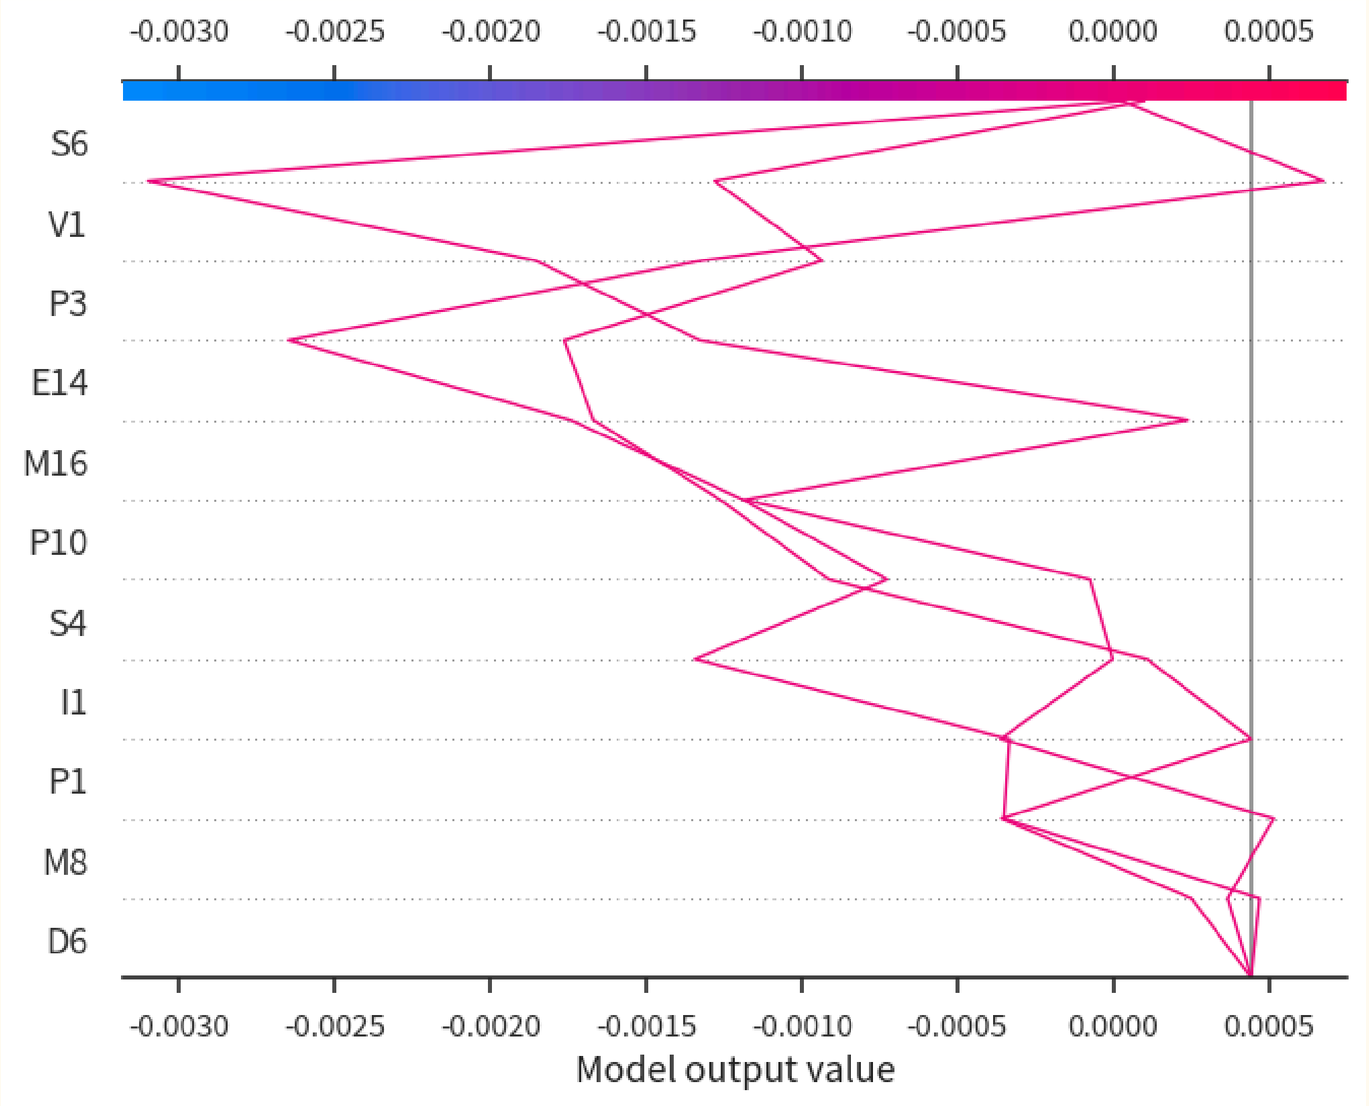

RESULT

最終結果與表現評估

- **本研究策略在驗證期間之最終評分為 10.04 分**

表現約位於整體排名前30%，在未進行高度調參與模型複雜化的情況下，策略仍能維持穩定且合理的風險調整後表現，顯示所建構之特徵篩選與策略設計具一定穩定性與可行性。

- **未來工作**

後續可於訊號轉換階段加入更嚴格的風險控管機制，以提升策略穩定性。

策略績效與風險表現

上圖：累積資金曲線

策略隨時間累積的資金變化情形

下圖：回撤曲線

策略在任一時間點，相對於過去最高資金水準的下跌幅度。

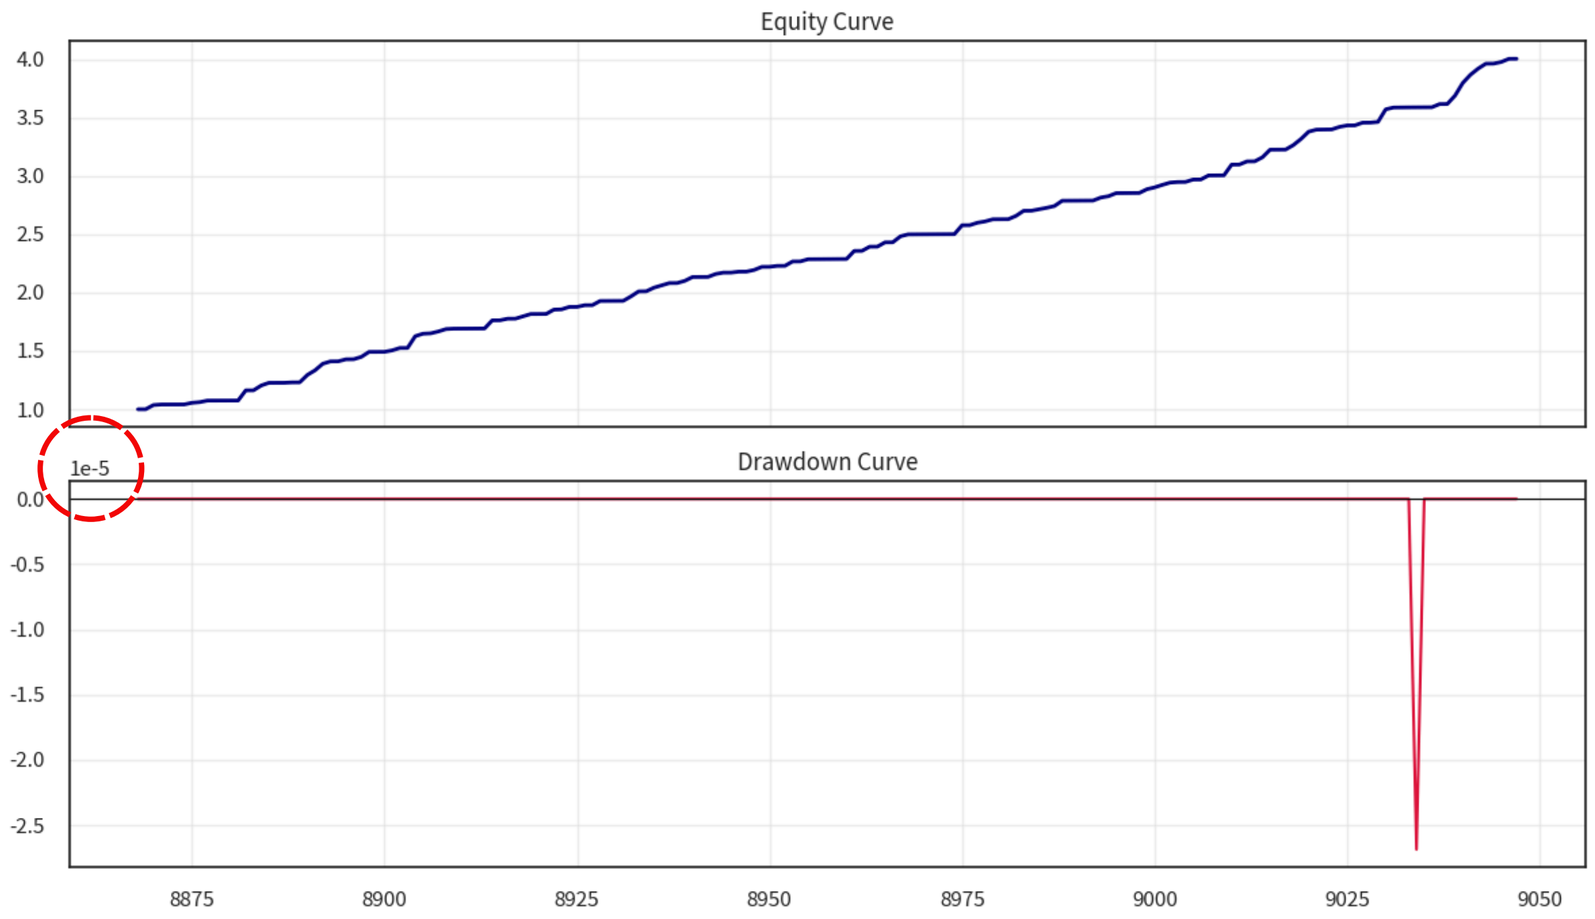

※ 範例：假設回撤 −0.004
如果在之前資金最高的時候進場，到這個時間點為止，會暫時虧約 0.4%。

理想的策略

- 資金穩定上升
- 撤幅度小且持續時間短

在獲利的同時能有效控制風險

Thank You