機器學習期末報告

Transformer 模型發展脈絡與應用

中山大學應用數學所 薄育文
中山大學應用數學所 葉宇倫

目錄

01 報告摘要

02 RNN介紹

03 Transformer介紹

04 RNN vs Transformer

05 Transformer 應用實作

06 結論

01

報告摘要

本報告會詳細地介紹 Transformer 模型的整體架構、核心機制與訓練超參數設定。透過編碼器與解碼器的雙塔結構，Transformer 能夠同時處理整個序列並利用多頭自注意力機制動態聚焦關鍵資訊，進而克服 RNN 在長期依賴與串行處理上的限制。在實作層面，本報告也說明了詞嵌入維度、注意力頭數、前饋層寬度、詞彙表大小等重要超參數對模型學習能力的影響，並結合 warm-up + 遞減式學習率策略，提升訓練穩定性與效率，Transformer 不僅展現出優異的學習表現，也已成為現代 NLP 模型設計的核心基礎。

02

RNN介紹

$$h_t = tanh(WX_t + Uh_{t-1} + b)$$

$$y_t = softmax(Vh_t)$$

記號	說明
X_t	第 t 時刻的輸入（例如：單字編碼、語音片段、股價等）
h_t	隱藏狀態（hidden state），是模型的記憶，會隨時間遞推
y_t	預測輸出（output），例如類別機率分布、下一字預測等
W	輸入權重矩陣：將X_t映射到隱藏層空間
U	遞歸權重矩陣：將前一個狀態 h_{t-1}傳遞進來
b	偏差項，形狀與隱藏狀態相同，能加強模型彈性
V	輸出權重矩陣：將隱藏狀態 h_t 映射為輸出向量

接收輸入 X_t

↓

結合過去記憶 h_{t-1}

↓

計算目前狀態 $h_t = tanh(WX_t + Uh_{t-1} + b)$

↓

產生輸出值 $y_t = softmax(Vh_t)$

RNN架構圖 →

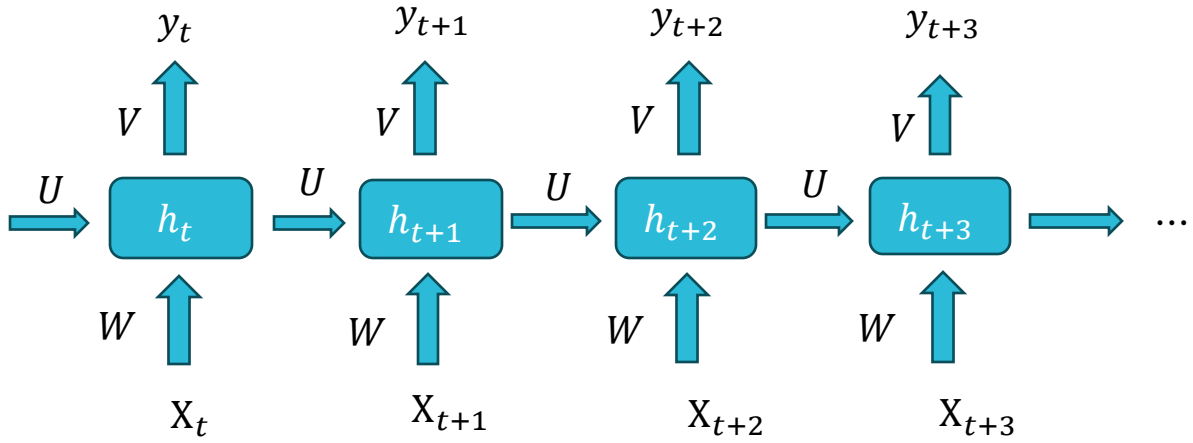

RNN 的優缺點

優點	說明
可處理序列資料	RNN 是為了處理時間序列或語言這類有「前後順序」的資料而設計，例如：語音辨識、自然語言生成等。
參數共享	所有時間步共享一組參數 W , U, V 使得模型具有更少的參數。

缺點	說明
梯度消失 / 爆炸	反向傳播時需連乘 $\frac{\partial h_t}{\partial h_{t-1}}$，造成梯度數值不穩定，無法學習長期依賴
串行計算效率低	必須按時間步順序依序計算 h_t，無法並行化，訓練速度慢
記憶容量有限	隱藏狀態 h_t 被動混合舊記憶與新輸入，且沒有主動控制記憶機制

03

Transformer介紹

Transformer架構圖

Input Embedding：
將輸入的文字轉換為對應的向量表示。

Positional Encoding：
由於 Transformer 本身不處理時間順序，我們需要加入位置資訊來保留詞序。

Multi-Head Attention：
核心機制，模型可同時從多個角度關注不同詞之間的關係。

Add & Norm：
殘差連接加上正規化，穩定訓練過程、加速收斂。

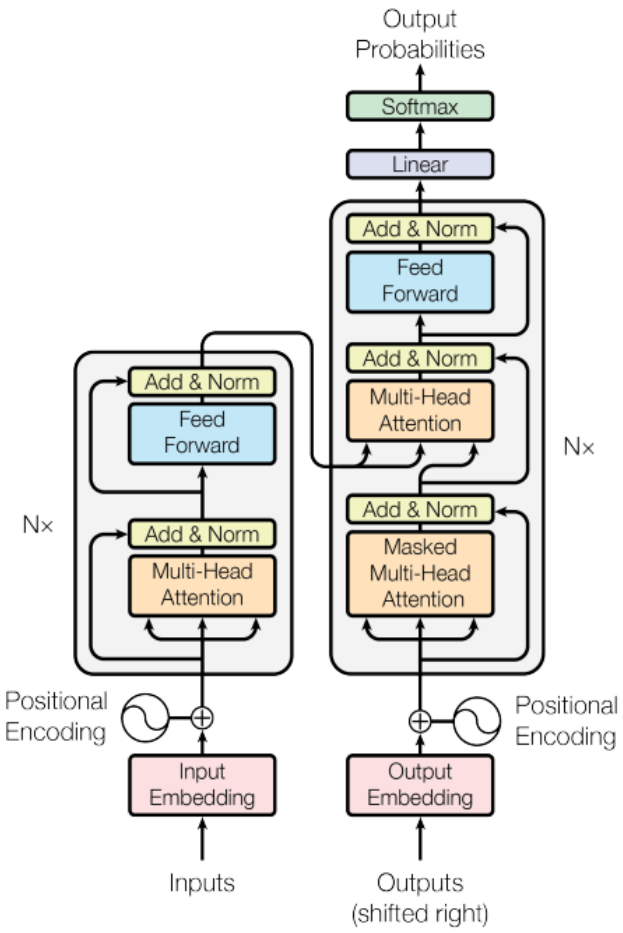

Figure 1: The Transformer - model architecture.

04

RNN vs Transformer

Introduction & Background（從 RNN 到 Transformer）

RNN：順序計算的瓶頸

傳統模型：RNN / LSTM / GRU
↓
逐步生成 hidden state
↓
優點：適合建模序列（如語言）
缺點：計算完全串行、無法並行
長序列計算慢，難訓練；梯度消失。

↓

引入 Attention 注意力機制 緩解訊息瓶頸

RNN + Attention
↓
加入注意力模塊，聚焦重要輸入位置
↓
優點：改善長距離依賴建模能力
缺點：依然使用 RNN，還是串行計算

Introduction

為解決 RNN 順序計算問題的研究：嘗試使用 CNN

Extended Neural GPU / ByteNet / ConvS2S
↓
將CNN 作為編碼器，支持輸入並行
↓
存在問題：訊息傳遞仍受限制（ConvS2S 是線性，ByteNet 是對數級），遠距離依賴建模仍困難

↓

Memory Network：注意力機制減少 RNN 的遞迴

End-to-End Memory Network
↓
不再依賴 RNN，使用多輪注意力從“記憶”中讀取信息
↓
存在問題：仍然有多輪遞迴過程（multi-hop attention），並不高效

↓

Transformer：不再使用 RNN 和 CNN，只用 Self-Attention 自注意力機制

Transformer 架構
↓
完全基於 Self-Attention，輸入每個位置彼此之間做注意力（Q*K），可以完全並行訓練所有位置；
多頭注意力（Multi-Head Attention）提升表達能力
↓
優點：並行訓練高效；建模遠距離依賴只需一次注意力操作（O(1)）；
在翻譯、語言建模等任務上刷新 SOTA

Background

05

Transformer 應用實作

介紹
data

資料集介紹(ted_hrlr_translate/pt_to_en)：

在自然語言處理領域中，機器翻譯是核心任務之一，而優質的雙語平行語料對於模型的訓練與評估至關重要。我們所使用的資料集是由 TensorFlow Datasets 所整理提供的一個高品質葡萄牙文（Portuguese）對英文（English）的平行語料資料集，資料來源為 TED Talks 的多語字幕翻譯，內容涵蓋廣泛的主題與語境，具有高度語意多樣性與實用性。

資料來源與背景：

本資料集原始資料來自 IWSLT（International Workshop on Spoken Language Translation）研討會中，由 Hassan et al. (2018) 發表的 TED Talks 多語翻譯語料。Harvard NLP 團隊進一步處理後，將其整理為 ted_hrlr_translate 系列，並收錄於 TensorFlow Datasets（TFDS）中供開發者與研究人員使用。

資料集的切分

這份資料集大約包含 50,000 筆訓練資料、1,100 筆驗證資料和 2,000 筆測試資料，內容涵蓋各種不同的語句和用法，可以用來訓練翻譯模型、調整模型參數，或是在訓練完成後拿來測試表現。這些資料可以幫助模型學會更自然的語言對應關係，讓最終的翻譯結果更貼近真實語言的使用情境。

編譯文字(tokenizer)

Tokenizer的主要功能把「人類語言」轉換成「機器能理解的數字序列」

example：

7915 ----> T
1248 ----> ran
7946 ----> s
7194 ----> former
13 --------> is
2799 ----> awesome
7877 ----> .

超參數	說明
num_layers = 6	編碼器 / 解碼器層數 ， 層越多，網路越深，可學到更複雜的語義與上下文
d_model = 512	詞向量（隱藏狀態）維度 每個 token 被嵌入成 512 維向量；維度越大，資訊容量越高
dff = 2048	前饋全連接層（FFN）寬度 內部兩層 MLP 的中繼維度，通常設為 4×d_model
num_heads = 8	多頭注意力的頭數 將 512 維切成 8 頭並行計算注意力 (512/8 = 64)
input_vocab_size = tokenizer_pt.vocab_size + 2	源語言詞彙表大小 tokenizer_pt 字典 + 特殊符號 <pad> <unk> 等
target_vocab_size = tokenizer_en.vocab_size + 2	目標語言詞彙表大小 tokenizer_en 字典 + 特殊符號
dropout_rate = 0.1	隨機丟棄率 訓練時 10 % 結點隨機關閉，防止 overfitting
Accuracy = SparseCategoricalAccuracy	評估指標 計算每步預測 token 是否等於真實 token（稀疏 one-hot）
Loss = SparseCategoricalCrossentropy	損失函數 訓練過程最大化正確 token 的對數機率

模型所使用的超參數

超參數	說明
BUFFER_SIZE = 20000	資料隨機緩衝大小 先將 2 萬筆樣本放進記憶體資料池，再亂序抽樣 → 提升批次抽樣的隨機性
BATCH_SIZE = 64	每次反向傳播的樣本數 一次餵 64 句對映 (src, tgt) 到 GPU；太大佔記憶體，太小收斂慢
MAX_LENGTH = 40	句子截斷 / 填補長度上限 超過 40 token 的序列將被截短；不足者用 <pad> 補齊 → 控制計算量
EPOCHS = 20	完整掃描資料次數 整個語料重覆訓練 20 遍；若早停 (early-stopping) 條件滿足會提前結束

模型所使用的超參數

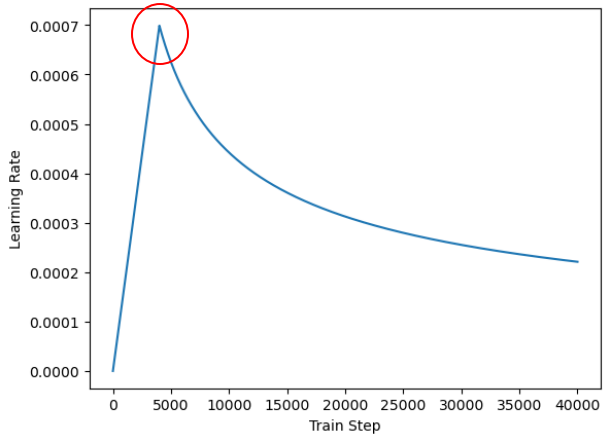

$$\text{lrate} = d_{\text{model}}^{-0.5} \cdot \min\left(\text{step_num}^{-0.5},\ \text{step_num} \cdot \text{warmup_steps}^{-1.5}\right)$$

參數說明 : Step number = 40000

Warmup steps = 4000

Transformer翻譯	真實意思
this is a problem that we have all of us all .	this is a problem we have to solve .
so i 'd like to share some of those things with you very short things that had very little .	so i 'll just share with you some stories very quickly of some magical things that have happened .

Transformer 模型在 TED 演講葡萄牙文翻譯英文任務上，BLEU-4 分數（含平滑）為 0.2481，這代表模型已具備一定的翻譯能力，能捕捉較長片語的語意對應。然而，該分數尚有提升空間，或許可從擴充訓練資料、多層注意力機制調整、或融合語言模型等方向優化，進一步提升翻譯流暢度與準確性。

且模型每個注意力頭分配注意力的模式不同，有的更集中於特定詞彙（例如 Head 3、Head 4 對於 primeiro, livro 的關注較明顯），有的則較為分散。這反映多頭注意力幫助模型從多角度捕捉詞彙間的依賴關係。

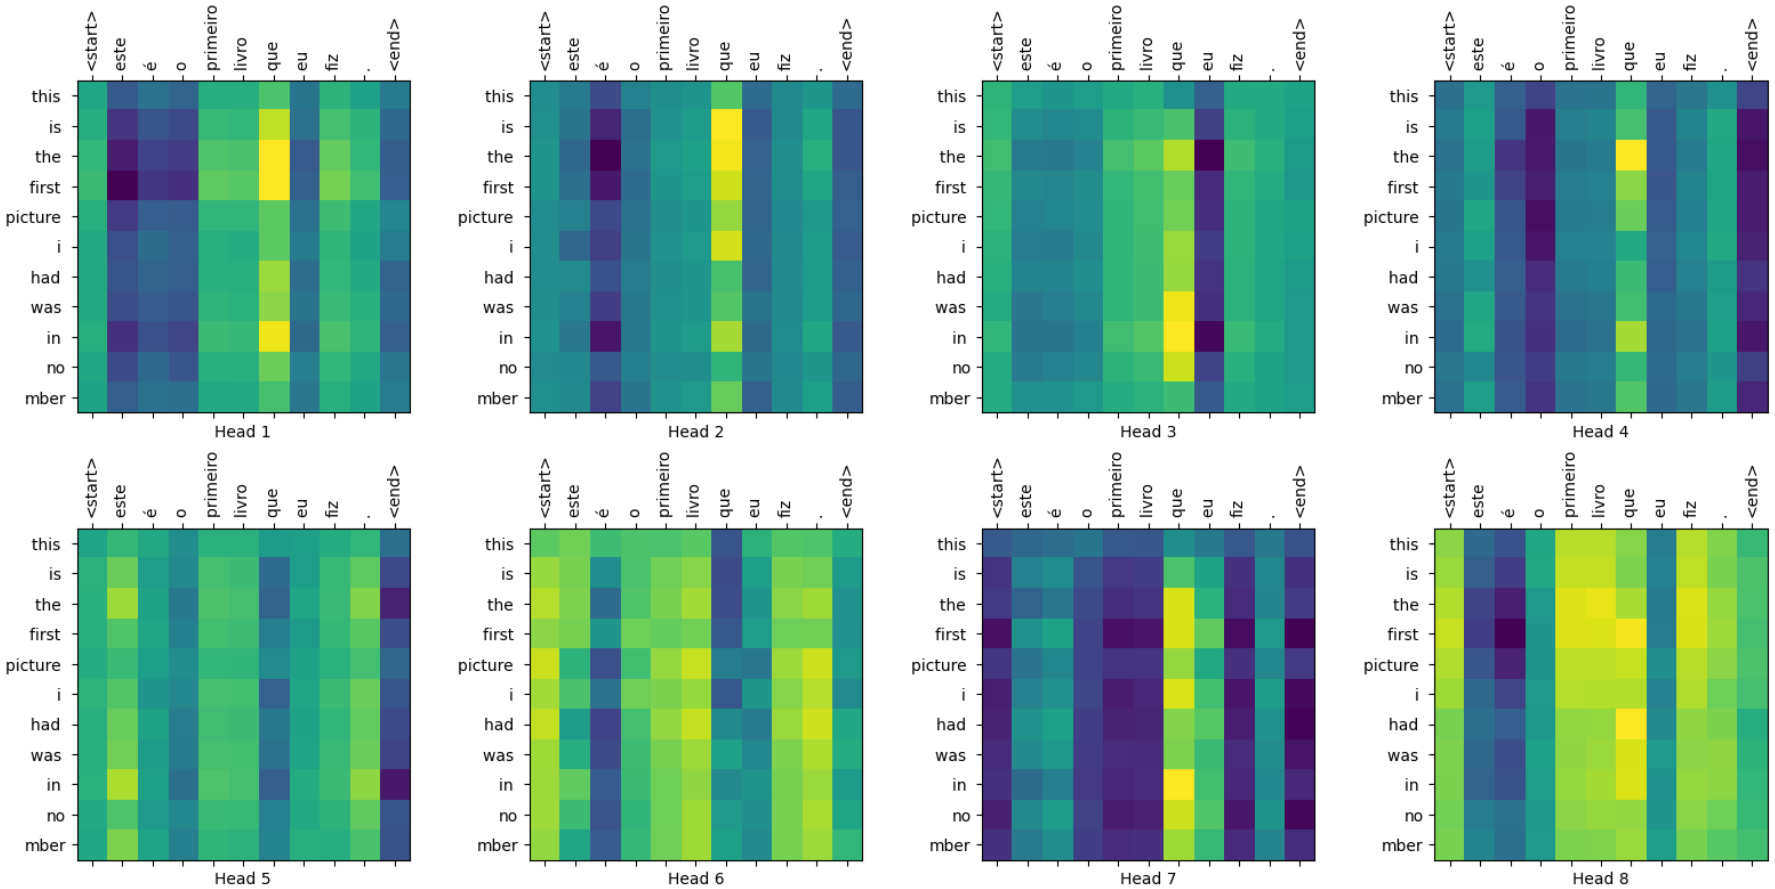
Head 1
Head 2
Head 3
Head 4
Head 5
Head 6
Head 7
Head 8
<start>
este
é
o
primeiro
livro
que
eu
fiz
.
<end>
this
is
the
first
picture
i
had
was
in
no
mber

06

結論

架構創新：Transformer 拋棄 RNN 結構，改以全注意力機制，提升並行運算效率與序列建模能力。

長距依賴強：透過多頭注意力，能有效捕捉遠距詞彙間的關聯，解決 RNN 長期記憶不足的問題。

結論1

結論2

結論4

結論3

超參數關鍵：模型表現與 d_model、num_layers、num_heads 等超參數密切相關，需精心設計。

學習率調控穩定訓練：使用 warm-up + 遞減策略，有助於穩定訓練過程與提升最終效果。

END

Reference:

1. https://github.com/huangyf2013320506/bilibili_repository

2. https://www.tensorflow.org/text/tutorials/transformer